
Neyron nutq sintezi

Texnik asoslar

To'lqindan tokengacha, tokendan modelgacha. Zamonaviy TTS tizimlari ichkarida qanday ishlashi — sohaga yangi kirgan muhandis uchun.

Bu hujjat haqida

Zamonaviy nutq sintezi haqidagi maqolalar odatda o'rtadan boshlanadi: «kodek tokenlari», «avtoregressiv dekode», «RVQ qatlamlari». Bu atamalar bir-biriga bog'lanmasa, butun soha sehr bo'lib ko'rinadi.

Bu hujjat boshidan boradi — ovoz kompyuterda qanday saqlanishidan. Har bir bosqichda bitta savolga javob beriladi va keyingi bosqich shu javobdan kelib chiqadi. Formulalar minimal, o'rniga aniq raqamlar: nechta bit, nechta token, nechta soat.


Oxirida nima uchun ba'zi modellar tirik, ba'zilari robotdek gapirishini tushunasiz — va nima uchun yangi til qo'shish shunchalik qiyinligini.

Hujjat quyidagi savollarga javob beradi:

- Ovoz raqamlar sifatida qanday ko'rinadi va u qancha joy egallaydi?
- Nima uchun model to'lqinni to'g'ridan-to'g'ri bashorat qila olmaydi?
- «Audio token» nima va u qayerdan keladi?
- Nima uchun eski modellar bir tekis, yangilari esa ifodali gapiradi?
- Nima uchun modelga yangi til o'rgatish kutilganidan qiyin?

Ovoz — bu raqamlar ketma-ketligi

Havodagi tovush — bosimning tebranishi. Mikrofon uni kuchlanishga, analog-raqamli o'zgartirgich esa raqamlarga aylantiradi. O'zgartirgich sekundiga minglab marta bosimni o'lchaydi va har bir o'lchov natijasini butun son sifatida yozadi.



Rasm 1. Uzlaksiz to'lqin muntazam oraliqlarda o'lchanadi. Ko'k nuqtalar — saqlanadigan yagona narsa. Ular orasidagi hamma narsa yo'qoladi.

Ikkita parametr hamma narsani belgilaydi. Diskretlash chastotasi (sample rate) — sekundiga nechta o'lchov olinishi. Bit chuqurligi (bit depth) — har bir o'lchov necha bit bilan yozilishi.

Qiymat	Nimani anglatadi	Qayerda
8 000 Hz	sekundiga 8 ming o'lchov	telefon liniyasi
16 000 Hz	nutqni tanish uchun yetarli	ASR modellari
24 000 Hz	TTS uchun amaldagi standart	Qwen3-TTS, Orpheus
44 100 Hz	musiqa sifati	CD, studiya

Nima uchun aynan shu raqamlar? Nyquist teoremasiga ko'ra, chastotani yozib olish uchun diskretlash tezligi undan kamida ikki barobar yuqori bo'lishi kerak. Inson nutqidagi muhim ma'lumot taxminan 8 kHz gacha joylashgan — shuning uchun 16 kHz nutqni tanish uchun yetadi. Tabiiy jaranglashi uchun esa yuqori chastotalar ham kerak, shundan 24 kHz.

Hisoblab ko'ring


24 000 Hz, 16 bit, mono ovoz — bu sekundiga $24\,000 \times 16 = 384\,000$ bit, ya'ni 48 kilobayt. Bir daqiqa — 2,8 megabayt. Bir soat toza yozuv — taxminan 165 megabayt siqilmagan holda. Bu raqamni yodda tuting: butun soha shu son bilan kurashadi.

03

Asosiy muammo: axborot tezligi

Endi model tomonidan qaraymiz. Til modeli matnni token ketma-ketligi sifatida bashorat qiladi. O'rtacha inson daqiqasiga 150 ta so'z aytadi — bu taxminan sekundiga 4 ta so'z, ya'ni juda taxminiy hisobda 50 bit ma'lumot.

Xuddi shu soniyadagi audio esa 384 000 bit. Farq — taxminan yetti ming barobar.




Rasm 2. Bir soniya nutqning uch xil ko'rinishdagi hajmi. Shkala logarifmik — ustunlar orasidagi haqiqiy farq ko'ringanidan ancha katta.

Bu nima degani? Agar modelni to'liq qiymatlarini bevosita bashorat qilishga majbur qilsak, u bir soniyalik nutq uchun 24 000 ta qaror qabul qilishi kerak bo'ladi. Bitta jumla — 100 ming qaror. Bu hisoblash jihatidan ham, o'rganish jihatidan ham amaliy emas.

Butun soha tarixi — shu raqamni kamaytirish urinishlari tarixi. Ikkita yechim topilgan, va ular sizga tanish bo'lgan ikki avlod modellarni tug'dirgan.

Birinchi avlod: spektrogramma

Birinchi g'oya fizikadan keladi. To'lqinni vaqt bo'yicha qisqa bo'laklarga bo'lib, har bir bo'lakda qaysi chastotalar qanchalik kuchli ekanini hisoblaymiz. Natija — spektrogramma: gorizontaal o'q vaqt, vertikal o'q chastota, yorqinlik esa quvvat.



Rasm 3. Yuqorida — xom to'lqin. Pastda — o'sha ovozning spektrogrammasi. Bir xil ma'lumot, lekin ancha ixcham va tuzilmaviy ko'rinishda.

Amalda mel-spektrogramma ishlatiladi. Mel shkalasi inson eshitishiga moslashtirilgan: quyi chastotalarni batafsil, yuqorilarini qo'polroq beradi — chunki quloq ham xuddi shunday ishlaydi. 300 va 400 Hz orasidagi farqni sezamiz, 8 000 va 8 100 Hz orasidagini esa yo'q.

Odatdagi sozlama: 80 ta mel kanali, sekundiga 80 ta kadr. Ya'ni sekundiga $80 \times 80 = 6\,400$ ta son — 24 000 o'rniga. Taxminan 60 barobar qisqarish.

Shu asosda ikki bosqichli tizim qurilgan: birinchi model matndan mel-spektrogramma yasaydi (Tacotron 2, FastSpeech), ikkinchisi — vokoder — spektrogrammadan to'lqin tiklaydi (WaveNet, HiFi-GAN). Bu arxitektura 2017–2022 yillarda hukmron bo'lgan.

Lekin unda tuzatib bo'lmaydigan kamchilik bor — va bu keyingi bo'limning mavzusi.


Nima uchun eski modellar robotdek gapiradi

Bitta jumlaning o'ylang: «U keldi.» Uni yuzlab xil aytish mumkin — hayajon bilan, xafa holda, savol ohangida, sekin, tez. Barchasi to'g'ri.


Bu bir-ko'pga muammosi (one-to-many problem). Bitta matnga ko'plab to'g'ri audio mos keladi.

Tacotron tipidagi modellar regressiya bilan o'rgatiladi: bashorat va haqiqat orasidagi farqni (L1 yoki L2 xatolik) minimallashtiradi. Matematik jihatdan bunday xatolikni minimallashtiruvchi yagona javob — barcha to'g'ri javoblarning o'rtachasi.

Regressiya: o'rtachani bashorat qiladi



Sampling: taqsimotdan tanlaydi



Rasm 4. Chapda — regressiya: model ikkita tabiiy variant orasidagi o'rtachani tanlaydi, va hech kim shunday gapirmaydi. O'ngda — sampling: model har safar taqsimotdan tirik variant tanlaydi.

Asosiy tushuncha


«Robotdek» ovoz — bu data yetishmasligi emas va model kichikligi ham emas. Bu o'rtachalashning bevosita natijasi. Modelni cheksiz data bilan o'rgatsangiz ham, regressiya maqsadi saqlansa, natija baribir tekis chiqadi. Ifodalilik uchun modelning bashorat qilish usuli o'zgarishi kerak edi.

06

Ikkinchi avlod: neyron kodek

Ikkinchi g'oya boshqa yo'ldan boradi: audioni diskret belgilar ketma-ketligiga aylantirish. Xuddi matn harflardan iborat bo'lgani kabi, audio ham cheklangan «alifbo» dan iborat bo'lsin.


Buning usuli — vektor kvantlash (vector quantization). Neyron tarmoq audioning kichik bo'lagini vektorga siqadi. Keyin oldindan o'rgatilgan lug'atdan (codebook) unga eng yaqin vektor topiladi va faqat o'sha yozuvning raqami saqlanadi.



Rasm 5. Kul rang nuqtalar — haqiqiy audio vektorlari. Ko'k kvadratlar — lug'atdagi yozuvlar. Har bir nuqta o'zining eng yaqin yozuvi raqami bilan almashtiriladi.

Agar lug'atda 1 024 ta yozuv bo'lsa, har bir bo'lak atigi 10 bit bilan yoziladi. Lekin bitta lug'at yetarli aniqlik bermaydi — nuqta va unga eng yaqin yozuv orasida har doim xato qoladi.

Yechim — qoldiqli kvantlash (residual quantization, RVQ). Birinchi lug'at qo'pol yaqinlashtirish beradi. Qolgan xato ikkinchi lug'at bilan kvantlanadi. Uning xatosi — uchinchi bilan. Va hokazo.




Rasm 6. Har bir yangi kvantlash qatlami avvalgisining xatosini kamaytiradi. Birinchi qatlamlar ovozning asosiy shaklini, oxirgilari nozik detallarni — nafas, shivir, tembr soyalarini tashiydi.

Endi aniq raqamlarga qaraymiz.

Model	Kadr / sek	Qatlam	Natija
EnCodec (Meta)	75	8 × 10 bit	6 000 bit/s
DAC (Descript)	86	9 × 10 bit	~7 700 bit/s
Qwen3-TTS	12	ko'p qatlamli	juda qisqa ketma-ketlik

Qwen3-TTS ning 12 Hz tokenizeri nima uchun muhim: bir soniyalik nutq atigi 12 ta ustun beradi. EnCodec da bu 75 ta edi. Til modeli uchun ketma-ketlik olti barobar qisqaradi — demak

tezroq, arzonroq va uzun kontekstda barqarorroq.




vaqt --> har bir ustun = 1/12 soniya

Rasm 7. Kodlangan audio shunday ko'rinadi: har bir ustun — vaqtning bir bo'lagi, har bir qator — kvantlash qatlami. Model shu raqamlarni bashorat qiladi, to'liqini emas.

07

Uchinchi avlod: kodek til modeli

Audio endi diskret raqamlar jadvali. Bu til modeli ishlaydigan formatning aynan o'zi. Demak, matn tokenlarini bashorat qiladigan arxitekturani audio tokenlarini bashorat qilishga o'rgatish mumkin.



Rasm 8. Zamonaviy TTS tizimining umumiy sxemasi. Referens audio ixtiyoriy — u berilsa, model o'sha ovozni taqlid qiladi.

Va bu yerda muhim narsa yuz beradi. Til modeli o'rtachani bashorat qilmaydi — u har bir qadamda ehtimollik taqsimotini chiqaradi va undan namuna oladi (sampling). Ikki xil intonatsiya mumkin bo'lsa, model o'rtasini olmaydi: u bittasini tanlaydi.

Aynan shu sabab yangi avlod modellari tirik jaranglaydi. Ifodalilik alohida qo'shilgan xususiyat emas — u bashorat usulining tabiiy natijasi.

Ovoz klonlash qanday ishlaydi

2023-yilda VALL-E maqolasi soddagina hiyla ko'rsatdi. Model «davom ettirish» uchun o'rgatilgan. Unga 3 soniyalik referens audio tokenlarini boshlanish sifatida bersangiz, u davomini o'sha ovozda yozadi — chunki tabiiy davom aynan shunday bo'ladi.

Hech qanday qo'shimcha train yo'q. Bu — til modellaridagi kontekst ichida o'rganish (in-context learning) ning audio versiyasi. Shu bitta kuzatuv butun zero-shot klonlash sohasini ochib bergan.

Amaliy oqibat

Sampling harorati (temperature) ifodalilikni boshqaradi. Past harorat — barqaror, lekin tekis ovoz. Yuqori harorat — jonli, lekin ba'zan model adashadi: so'zlarni takrorlaydi yoki tushirib qoldiradi. Ishlab chiqarish tizimlarida bu muvozanat doimiy sozlash mavzusi.

08

Muqobil yo'l: flow matching

Avtoregressiv modellar tokenlarni birma-bir chiqaradi — bu sekin va xato to'planishiga moyil. Ikkinchi oila boshqacha ishlaydi: shovqindan boshlab, butun audioni bir vaqtda, bir necha qadamda asta-sekin tozalaydi.

Bu oilaga Voicebox (Meta), Matcha-TTS, E2-TTS va F5-TTS kiradi. Ular parallel ishlaydi, tezroq va barqarorroq — so'z tushirib qoldirmaydi.

Evaziga: xilma-xillik kamroq. Bir xil matn bir xil sozlamalarda odatda bir xil natija beradi. Aniqlik va takrorlanuvchanlik kerak bo'lsa — bu ustunlik. Maqsad hissiy jonlilik bo'lsa — cheklov.

	Avtoregressiv	Flow matching
Ifodalilik	yuqori	o'rtacha
Barqarorlik	o'rtacha	yuqori
Tezlik	sekin, ketma-ket	tez, parallel
Xarakterli xato	takror, tushib qolish	tekis intonatsiya
Vakillar	VALL-E, Qwen3-TTS, Orpheus	Voicebox, F5-TTS

09

Nima uchun yangi til qo'shish qiyin

Bu bo'lim past resursli tillar bilan ishlaydiganlar uchun eng muhimi.

Yaxshi xabar. Kodek qatlami tilga bog'liq emas. U shunchaki audioni siqadi — o'zbek, arab yoki xitoy nutqi uning uchun farqi yo'q. Ya'ni tokenizerni qayta o'rgatish shart emas.

Yomon xabar. Modelning qolgan qismi tilga juda bog'liq. U matn belgilarini tovushlarga qanday bog'lashni, qaysi bo'g'in urg'uli bo'lishini, jumla oxirida ohang qanday tushishini o'rgangan — va bularning barchasi o'rgangan tillari uchun.

Natijada aksent oqishi yuz beradi: yangi tilda o'rgatilgan model o'zi biladigan eng yaqin tilning ohangini olib keladi. Amaliyotda bu aniq kuzatilgan — bengal tilida fine-tune qilingan model bengalcha so'zlarni to'g'ri talaffuz qiladi, lekin hind ohangi bilan.

Grafema va fonema

Modelga matnni ikki xil berish mumkin. Grafema — oddiy yozuv, «salom». Fonema — tovush belgilari, xalqaro IPA alifbosida.

Amaliy kuzatuv shunday: fonema kiritish begona aksentni kamaytiradi, chunki model tovushni bevosita oladi va yozuv qoidalarini taxmin qilmaydi. Lekin ayni paytda ovoz robotroq chiqadi — fonemalar yozuvdagi ba'zi nozik ishoralarni yo'qotadi. Bu yechilmagan muvozanat.

Eng birinchi tekshiruv

Yangi tilga urinishdan oldin bitta narsani tekshiring: modelning matn tokenizeri sizning tilingizni normal bo'laklarga ajratadimi? Agar har bir harfni alohida token qilib yuborayotgan bo'lsa, model tilni o'rganish uchun ancha ko'p data va qadam talab qiladi. Bu besh daqiqalik tekshiruv bir necha oylik ishni tejaydi.

10


Data: miqdor va sifat

Nechta soat kerak? Javob vazifaga qarab keskin farq qiladi.

Vazifa	Taxminiy hajm	Izoh
Ovoz klonlash (zero-shot)	3-10 soniya	train yo'q, faqat referens
Mavjud tilda yangi ovoz	3-20 soat	bitta spiker, toza yozuv
Yangi til qo'shish	50-150 soat	ko'p spikerli bo'lishi shart
Noldan o'rgatish	10 000+ soat	amalda tavsiya etilmaydi

Yangi til uchun ko'p spikerlilik shart — chunki model tilning umumiy qonuniyatlarini o'rganishi kerak, bitta odamning gapirish odatini emas. Odatiy strategiya ikki bosqichli: avval katta ko'p spikerli korpusda til o'rgatiladi, keyin kichik toza yozuvda kerakli tembr o'rnatiladi.

Internetdan yig'ilgan data hech qachon to'liq ishlatilmaydi. Filtrlashdan keyin qancha qolishini oldindan bilgan ma'qul.



Rasm 9. «In-the-wild» data uchun odatiy yo'qotish. 100 soat xom audiodan train uchun yaroqli 35–45 soat qoladi. Agar 70 foizdan ko'pi o'tayotgan bo'lsa — filtr juda yumshoq.

Sifat mezonlari miqdordan muhimroq: yozuv toza (SNR yuqori), aks-sado kam, transkript aniq. Bitta noto'g'ri transkript qilingan segment o'nta toza segmentning foydasini yo'qqa chiqaradi — model xato bog'lanishni ham xuddi shunday ishonch bilan o'rganadi.

11

Natijani qanday o'lchash kerak

«Yaxshi chiqdi» — o'lchov emas. Sohada standartlashgan usullar bor.

MOS (Mean Opinion Score) — asosiy o'lchov. Tinglovchilar namunani 1 dan 5 gacha baholaydi, o'rtacha olinadi. Metodikasi ITU-T P.800 va P.808 standartlarida belgilangan: nechta tinglovchi, qanday sharoitda, qanday tartibda.



Rasm 10. MOS shkalasi va amaldagi mo'ljallar. Inson nutqi odatda 4,5 atrofida baholanadi — 5 emas, chunki yozuv sifati ham hisobga olinadi.

CMOS — ikki modelni bevosita solishtirish. Tinglovchi ikkita namunani eshitib, qaysi biri yaxshiroq va qanchalik ekanini belgilaydi. Kichik farqlarni MOS dan sezgirroq ushlaydi.

WER — tushunarlilikni avtomatik o'lchash. Sintez qilingan audioni nutq tanish tizimiga berib, matn qanchalik to'g'ri qaytishini hisoblaysiz. Yuqori xatolik — talaffuz muammosi belgisi.

Spiker o'xshashligi — tembr qanchalik saqlanganini o'lchaydi. Referens va natija vektorlari orasidagi kosinus yaqinligi.

Amaliy qoida

Avtomatik metrikalar (WER, o'xshashlik, UTMOS) har bir train'dan keyin — ular arzon va regressiyani darhol ko'rsatadi. Inson bahosi esa faqat muhim bosqichlarda — u qimmat, lekin yagona ishonchli hakam. Avtomatik metrika yaxshilanib, tinglovchiga yomonroq eshitiladigan holatlar muntazam uchraydi.

12

Qisqacha lug'at

Atama	Ma'nosi
Sample rate	Sekundiga olinadigan o'lchovlar soni (24 000 Hz)
Mel-spektrogramma	Chastota tasviri, inson eshitishiga moslashtirilgan
Vokoder	Spektrogrammadan to'lqin tiklovchi model
Codebook	Kvantlash lug'ati — tayyor vektorlar to'plami
VQ	Vektor kvantlash — vektorni lug'at raqamiga almashtirish
RVQ	Qoldiqli kvantlash — xatoni qatlamma-qatlam kamaytirish
Token	Model ishlaydigan diskret birlik
Avtoregressiv	Har bir tokenni avvalgilariga qarab chiqarish
Sampling	Taqsimotdan tasodifiy tanlash (o'rtacha olish emas)
Zero-shot	Qo'shimcha train'siz, faqat referens bilan
Fine-tune	Tayyor modelni yangi data'ga moslashtirish
Grafema	Yozuvdagi belgi
Fonema	Tovush birligi (IPA belgisi)
G2P	Yozuvdan tovushga o'tkazuvchi tizim
MOS	1-5 shkalasidagi o'rtacha inson bahosi
SNR	Foydali signalning shovqinga nisbati

13

Keyingi o'qish

Har bir bo'lim ortidagi birlamchi manbalar. Tartib — o'qish uchun tavsiya etilgan ketma-ketlik.

Kodek va tokenizer

- SoundStream (Google, 2021) — RVQ g'oyasining kelib chiqishi
- EnCodec (Meta, 2022) — eng ko'p ishlatilgan amalga oshirish
- DAC (Descript, 2023) — sifat bo'yicha sakrash va uning sababi

- Moshi / Mimi (Kyutai, 2024) — g'ayrioddiy batafsil texnik hisobot

Arxitektura

- Tacotron 2 (Google, 2017) — eski avlodni tushunish uchun
- AudioLM (Google, 2022) — semantik va akustik tokenlar ierarxiyasi
- VALL-E (Microsoft, 2023) — kodek til modeli va zero-shot klonlash
- Voicebox (Meta, 2023) — flow matching yondashuvi
- CosyVoice 2 / 3 (Alibaba) — ishlab chiqarish darajasidagi detallar

Data

- Whisper (OpenAI, 2022) — miqyosda zaif nazorat va filtrlash mezonlari
- Emilia / Emilia-Pipe (2024) — podkastdan korpus qurish, ochiq quvur
- LibriTTS-R — audiokitobdan TTS korpusi metodikasi
- MMS (Meta) — 1 100 dan ortiq til, past resursli tillar tajribasi

Baholash

- ITU-T P.800 — MOS ning asl standarti
- ITU-T P.808 — kraudsorsing orqali baholash metodikasi
- UTMOS, DNSMOS — avtomatik proksi baholar va ularning chegaralari

Bu soha tez o'zgaradi. Arxitekturalar va model nomlari yangilanadi, lekin bu hujjatdagi asosiy tushunchalar — axborot tezligi, kvantlash, o'rtachalash va sampling farqi — barqaror qoladi. Yangi modelni ko'rganingizda birinchi savol shu bo'lsin: u tokenlarni qanday hosil qiladi va bashoratni qanday chiqaradi?