
O'zbek TTS

Train yo'l xaritasi — 1000 soat miqyosida

YouTube'dan yig'ilgan minglab soat asosida sifatli, ifodali o'zbek nutq sintezi qurish: manba tanlashdan sun'iy ovoz yaratishgacha — tartib, raqamlar va har bosqichning o'tish sharti bilan.

Halol hisob: 1000 soat aslida qancha?

Har qanday katta loyiha ikkita songa tayanadi: qancha data bor va qancha hisoblash kuchi bor. Ikkalasini boshida halol hisoblab olamiz.

1000 soat xom YouTube audio filtrlashdan keyin taxminan 350–450 soat train uchun yaroqli data beradi. Bu yo'qotish emas, normadir — va bu qolgan miqdor maqsad uchun ortig'i bilan yetadi:

Vazifa	Kerakli hajm	Bizning holat
Yangi til o'rgatish (fine-tune)	50–150 soat	yetarli, zaxira bilan
Ko'p spikerli prosodiya bazasi	200–400 soat	aynan shu oraliqda
Noldan pretraining	10 000+ soat	yetmaydi — shuning uchun fine-tune


Hisoblash kuchi: 1.7B parametrli model, 350 soat data, 3–5 epoch — bitta A100/H100 da 1–2 hafta, RTX 4090 da gradient accumulation bilan 3–5 hafta. Disk: xom WAV ~165 GB, oraliq fayllar bilan 500 GB ajrating.

Strategik qaror

Noldan o'rgatilmaydi — ko'p tilli tayyor model olinadi va unga o'zbek «singdiriladi» (continued pretraining + fine-tune). Baza model allaqachon intonatsiya, emotsiya va nutq fizikasini biladi; biz faqat tilni qo'shamiz. Bu 10 000 soatlik talabni 300 soatga tushiradigan yagona yo'l.

Manba tanlash — data yig'ishdan oldin

Eng qimmat xato shu yerda qilinadi: «nima topilsa, shuni yuklaymiz». Model xarakterini arxitektura emas, data tarkibi belgilaydi. Faqat yangiliklar o'qigan model diktator bo'ladi; faqat vloglardan o'rgangani shovqinli bo'ladi.



Rasm 1. Maqsadli manba aralashmasi. Suhbat janri asosiy ulushni oladi — tabiiy prosodiya aynan jonli dialogda yashaydi.

Qat'iy chiqarib tashlanadigan manbalar:

- Dublyaj va ovozli tarjima — intonatsiya sun'iy, ritm lip-sync ostida buzilgan
- Doimiy fon musiqali kontent — ajratish artefakt qoldiradi, model uni o'rganadi
- Telefon/zoom yozuvlari — 8-16 kHz ship butun korpus sifatini tortadi
- Yarim ruscha kanallar — kod-almashinuv normal, lekin 50/50 aralash chalg'itadi

Ro'yxat kanal darajasida tuziladi, video darajasida emas. 100-200 ta sifatli kanal 1000 soatni beradi. Har kanalga yorliq: janr, taxminiy sifat, yozuv tizimi. Keyin bu yorliqlar aralashmani balanslashda ishlaydi. Kanal ID'sini saqlang — u spiker taxminida ham kerak bo'ladi.

O'tish sharti (gate)

Kanal ro'yxati tayyor, aralashma ulushlari taxminan mos, jami xom hajm 1000 soatdan kam emas.

03


Yig'ish va birlamchi tozalash

Quvur tartibi: yuklash → manba ajratish → spikerlarni ajratish → segmentlash. Har bosqich mustaqil, qayta ishga tushirilganda tugallangan ishni takrorlamaydi.

Manba ajratish (Demucs) faqat fon musiqasi bor joyda qo'llanadi va o'tgan har bir segment belgilanadi: ajratish eshitar-eshitilmas artefakt qoldiradi, va bunday segmentlar train setning 20 foizidan oshmasligi kerak. Toza audioga Demucs qo'llash — foydasiz degradatsiya.

Spikerlarni ajratish (pyannote): har videoda kim qachon gapirgani. Kanal ID + klaster raqami = taxminiy global spiker. Bir kanalda odatda bitta asosiy ovoz — bu taxmin ko'p holatda to'g'ri chiqadi.

Ustma-ust nutq tashlab yuboriladi — muzokarasiz. Podkastda bu 10-20%. Achinmang: bunday segment modelga «ikki ovoz bir vaqtda — normal» deb o'rgatadi.



Rasm 2. 1000 soatning odatiy taqdiri. Har bosqichda yo'qotish rejali. Oxirgi ustun — train'ga kiradigan haqiqiy hajm.

O'tish sharti (gate)


Quvur 50 soatlik namunada uchidan-uchiga o'tdi; har bosqich yo'qotish statistikasi chiqarildi; disk hisoblangan.

Transkripsiya — butun loyiha shi

Bu bosqichga alohida urg'u, chunki qoida shafqatsiz: transkript sifati = model sifatining yuqori chegarasi. Model xato yozilgan matnni ham xuddi to'g'risidek ishonch bilan o'rganadi. Yuz ming segmentda buni qo'lda tekshirib bo'lmaydi — tizim kerak.

Whisper large-v3 o'zbekchada o'rtacha ishlaydi — so'z xatolik darajasi (WER) taxminan 25-40%. 1000 soat uchun bu qabul qilib bo'lmaydi. Tartib shunday:

- Avval ASR'ni yaxshilang. Whisper'ni ochiq o'zbek korpusida (USC, 105 soat) fine-tune qiling. Bu 2-4 kunlik ish — va u butun 1000 soatga ishlaydi
- Ikki modeli konsensus. Har segmentni ikki mustaqil ASR bilan yozing. Mos kelganlar — ishonchli to'plam, farq qilganlar — past qatlamga
- Punktatsiyani tiklang. Vergul va nuqta TTS uchun pauza va ohang signali. Ularsiz prosodiya o'rganilmaydi



Rasm 3. Konsensus filtri. Ikki mustaqil model bir xil matnni chiqargan segment — deyarli aniq to'g'ri transkript. Farq — shubha belgisi.

Yozuv tizimi qarori hozir qabul qilinadi: ichki format — bitta yozuv (tavsiya: lotin). Kirill transkriptlar deterministik o'giriladi, apostroflar (o', g', tutuq belgisi) bitta shaklga keltiriladi. Aralash yozuvli korpus — sekin ta'sir qiladigan zahar: model bir tovushni ikki xil belgi bilan ko'rib, ikkalasini ham chala o'rganadi.

O'tish sharti (gate)

Qo'lda tekshirilgan 2 soatlik etalon to'plamda quvur transkripti $WER \leq 10\%$. Bunga yetmaguncha train boshlanmaydi — ASR'ga qaytib sarmoya qilinadi.

Sifat qatlamlari: tashlamaymiz, belgilaymiz

Oddiy yondashuv data'ni ikki chelakka ajratadi: o'tdi / o'tmadi. Bu isrof. Yaxshiroq usul — uch qatlam, va sifat belgisini modelga shart (conditioning) sifatida berish.



Rasm 4. Uch qatlam. C-qatlam ham train'ga kiradi — til bilimiga hissa qo'shadi — lekin model uni «past sifat» belgisi bilan ko'radi. Ishlatish paytida «A» so'raladi.

Mexanizm sodda: har segment manifestda sifat tegi oladi, teg train paytida kirishga qo'shiladi. Model shovqinni alohida o'lchov sifatida o'rganadi. Sintez paytida «toza» tegi berilsa — model faqat toza uslubda gapiradi. Shunday qilib shovqinli 130 soat ham foyda keltiradi, ovoz sifatini pastga tortmasdan.

Asosiy filtrlash mezonlari (barchasi konfiguratsiyada, kodda emas):

Mezon	Chegara	Nimadan saqlaydi
Segment uzunligi	2–20 soniya	chala so'zlar, monologlar
ASR ishonchi (avg_logprob)	> -1.0	noaniq transkript
Siqilish nisbati	< 2.4	ASR halyutsinatsiyasi (takrorlar)
Belgilar / soniya	5–25	sukut yoki tezlab ketish
Til ehtimoli (uz)	> 0.8	boshqa tildagi segmentlar

Til filtriga ehtiyot: o'zbek nutqida ruscha so'zlar tabiiy. Chegara kod-almashinuvli normal gaplarni o'ldirmasligini etalon to'plamda tekshiring.

O'tish sharti (gate)

Filtrdan keyin ≥ 300 soat; A-qatlam ≥ 50 soat; turli spikerlar ≥ 300 . Spiker soni sun'iy ovoz bosqichi uchun kritik.

06

Train'dan oldingi oxirgi tekshiruv: tokenizer

Yarim kunlik ikki test — va ular bir necha oylik behuda train'dan saqlaydi.

Matn tomoni. Baza model tokenizeriga 10 000 o'zbek jumla bering va token/so'z nisbatini o'lchang. Ingliz uchun bu ~ 1.3 . O'zbek uchun 3 dan oshsa — tokenizer har so'zni mayda bo'laklarga chaynayapti: model o'rganishi mumkin, lekin sekin va ko'p data bilan. Yechimlar, yomondan yaxshiga: shu holicha davom etish; lug'atga o'zbek tokenlari qo'shib embedding kengaytirish; fonema kiritishga o'tish.

Audio tomoni. 100 ta eng toza segmentni kodek orqali kodlab-dekodlab eshiting va avtomatik baho (UTMOS) oling. Bu — sifat shipi: model kodek rekonstruksiyasidan yaxshiroq ovoz chiqara olmaydi. Ship past bo'lsa, muammo train'da emas — boshqa baza model kerak.


O'tish sharti (gate)

Token/so'z ≤ 2.5 (yoki kengaytirish rejasi aniq); kodek rekonstruksiyasi qulog'ingizga va UTMOS'ga qoniqarli.

07

Train: uch fazali tartib

Hammasi birdaniga o'rgatilmaydi. Amaliy tajriba aniq: barcha qatlamlarni birga ochish — shovqinga yo'l. Ish uch fazaga bo'linadi, har birida o'z data'si, o'z learning rate'i va o'z maqsadi bor.



Rasm 5. Uch faza. Har keyingisi kichikroq learning rate bilan — avvalgi fazada o'rganilganni buzmaslik uchun. Faza uzunliklari nisbati ham taxminan shunday: birinchisi eng uzun.


Faza 1 — til singdirish. Data: B + C qatlamlar, barcha spikerlar, sifat teglari bilan. Ochiq qatlamlar: asosiy transformer va matn embedding'lari. Audio kodek muzlatilgan — u tilga bog'liq emas, teginish shart emas. Learning rate past ($1e-5$ tartibida), chunki maqsad baza modelni qayta yozish emas, unga yangi til qo'shish. Bu eng uzun faza.

Faza 2 — silliqlash. Data: faqat A-qatlam. Maqsad: o'rganilgan tilni toza, ifodali nutqqa keltirish. Qisqa — 1-2 epoch. Uzaytirsangiz model 70 soatlik to'plamga yopishib, xilma-xillikni yo'qotadi.

Faza 3 — ovoz qotirish — keyingi bo'limda, chunki avval ovozning o'zi yaratilishi kerak.

Nazorat: katastrofik unutish

Yangi til o'rgatilayotganda model eski bilimni yo'qota boshlashi mumkin — bu katastrofik unutish deyiladi. Nazorati arzon: har checkpoint'da inglizcha 10 ta jumla sintez qilib, ASR bilan tekshiring.



Rasm 6. Ikki stsenariy. To'g'ri learning rate'da ingliz ozgina pasayadi va barqarorlashadi. Juda baland LR'da o'zbek tezroq o'sgandek ko'rinadi, lekin baza bilim qulaydi — va u bilan birga intonatsiya boyligi ham.

Nega bu turkiy foundation uchun kritik

Keyinroq qozoq yoki qirg'iz qo'shilganda xuddi shu savol qaytadi: yangi til kirayotganda o'zbek buzilmayaptimi? Hozir qurilgan nazorat mexanizmi — har til uchun doimiy test to'plami — o'shanda ham ishlaydi. Qoida: yangi til har doim eski tillar data'sining bir qismi bilan aralash o'rgatiladi (replay), hech qachon yolg'iz emas.


O'tish sharti (gate)

Faza 2 checkpoint'ida: test to'plamda ASR-WER $\leq 15\%$; 10 ona tili sohibidan o'rtacha baho ≥ 3.8 ; ingliz nazorati qulamagan.

08

Sun'iy ovoz: hech kimga tegishli bo'lmagan tembr

Model ichida har bir spiker vektor (embedding) sifatida yashaydi. 300+ spikerdan keyin bu vektorlar uzluksiz fazoni to'ldiradi — va undagi har qanday nuqta ishlaydigan ovoz, hatto u yerda hech qachon real odam bo'lmagan bo'lsa ham.



Rasm 7. Spiker fazosi. Kul rang nuqtalar — train'dagi real ovozlar. Ko'k kvadratlar — fazodan olingan yangi sun'iy ovozlar. Real spikerga juda yaqin tushgan nomzod avtomatik rad etiladi.

Jarayon to'rt qadam:

- Barcha train spikerlarining vektorlarini chiqarish (shuning uchun ≥ 300 kerak edi)
- Ular ustida kichik generativ model o'rgatib, yangi nuqtalar olish — bir kunlik ish
- Verification filtri: har nomzod barcha real spikerlar bilan solishtiriladi; o'xshashlik chegaradan oshsa — rad. O'lchov natijalari saqlanadi: bu «ovoz hech kimga tegishli emas» degan hujjatli dalil
- Qulog'ingiz bilan 2-3 tasini tanlab, vektorlarni voice ID sifatida muhrlash

Faza 3 — qotirish. Tanlangan ovoz bilan 3-5 soat audio sintez qilinadi, eng yaxshi chiqqanlari saralanadi (past WER, baland UTMOS) va model shu to'plamda juda qisqa fine-tune qilinadi. Ovoz barqarorlashadi. Chegara qat'iy: bitta epoch — ortig'ida model o'z artefaktlarini kuchaytira boshlaydi.

O'tish sharti (gate)

Tanlangan ovoz verification'dan o'tgan; 100 jumlada tembr sakramaydi; o'rtacha baho ≥ 4.0 .


09

O'lchov intizomi

Oxirgi bo'lim eng zerikarli va eng muhimi. Ikki qoidaga rioya qilinmasa, yuqoridagi hamma ish o'zini aldash bilan tugaydi.

Birinchi qoida: validation kanal bo'yicha bo'linadi. Bitta videoning segmentlari ham train'ga, ham validation'ga tushsa, model «tanish» ovoz va uslubda tekshiriladi — metrikalar yolg'on yaxshi ko'rinadi, va siz buni juda kech sezasiz.

Noto'g'ri: segment bo'yicha



bitta videoning bo'laklari ikkala to'plamda —
metrika yolg'on yaxshi

To'g'ri: kanal bo'yicha



butun kanallar val'ga —
haqiqiy umumlashish o'lchanadi

Rasm 8. Chapda — keng tarqalgan xato: segmentlar tasodifiy bo'lingan. O'ngda — to'g'ri: butun kanallar validation'ga ajratilgan, model hech qachon ko'rmagan ovozlarda o'lchanadi. Ko'k — train, oq — validation.

Ikkinchi qoida: doimiy test to'plami. 200 jumla — oddiy gaplar, raqam va sanalar, savol-undov, uzun murakkab gaplar, ruscha so'z aralash gaplar. Har checkpoint shu to'plamda o'lchanadi: sintez → ASR → WER, spiker o'xshashligi, UTMOS. Inson bahosi (10+ tinglovchi, MOS va juftlik taqqoslash) — faqat muhim bosqichlarda: u qimmat, lekin yagona haqiqiy hakam.

Yakuniy eslatma

Bu hujjatdagi gate'lar sekinlashtirish uchun emas — ular eng qimmat xatodan saqlaydi: sifatsiz poydevor ustida haftalab GPU yoqish. Har gate arzon (soatlar yoki bir-ikki kun), har o'tkazib yuborilgan gate esa haftalarga tushishi mumkin. Shubha bo'lsa — orqaga qaytib o'lchang.